

IAD-006 – APRENDIZADO DE MÁQUINA II

Aula 01 – Árvores de Decisão



Prof. Dr. Arthur Henrique de Andrade Melani

Departamento de Engenharia Mecatrônica e Sistemas Mecânicos

Escola Politécnica da Universidade de São Paulo

melani@usp.br



Prof. Dr. Arthur Melani

melani@usp.br



O Laboratório de Confiabilidade da Universidade de São Paulo (USP) é um centro de pesquisa de ponta que utiliza ferramentas de inteligência artificial para resolver problemas complexos da indústria relacionados à gestão da manutenção.

<https://sites.usp.br/relab/>



- **Aprofundar os conhecimentos em Aprendizado de Máquina**, com foco em técnicas avançadas e aplicações práticas.
- **Explorar algoritmos supervisionados e não supervisionados**, incluindo:
 - Árvores de decisão e métodos ensemble
 - Mapas auto-organizáveis
 - Autoencoders
 - Máquinas de Boltzmann
- **Desenvolver habilidades práticas** em:
 - Implementação de modelos com Python
 - Interpretação e visualização de resultados
 - Avaliação de desempenho de modelos (acurácia, F1-score, AUC, etc.)
 - Balanceamento de bases de dados e tratamento de overfitting

Aula 01	29/07	Árvores de Decisão
Aula 02	05/08	Métodos Ensemble
Aula 03	12/08	XGBoost e Balanceamento de Datasets
Aula 04	19/08	Trabalho 1
Aula 05	26/08	Self Organizing Maps (SOMs)
Aula 06	02/09	Trabalho 2
Aula 07	09/09	Autoencoders
Aula 08	16/09	Máquinas de Boltzmann e Máquinas Restritas de Boltzmann
Aula 09	23/09	Clusterização e PCA
Aula 10	30/09	Trabalho 3

$$\textbf{Nota Final} = 0,3 \times \textbf{T}_1 + 0,3 \times \textbf{T}_2 + 0,3 \times \textbf{T}_3 + 0,1 \times \textbf{EX}$$

T_1 – Nota do Trabalho 1

T_2 – Nota do Trabalho 2

T_3 – Nota do Trabalho 3

EX – Nota dos Exercícios Práticos

O que é Machine Learning?


“O **Aprendizado de Máquina (AM)** é um subcampo da IA que estuda a capacidade de melhorar o desempenho de sistemas com base na experiência”.

Russell e Norvig (2022)

Aprendizado de Máquina AM

“processo de otimização dos parâmetros de um modelo por meio de técnicas computacionais, de modo que o comportamento do modelo reflita os dados ou a experiência”.

ISO/IEC 22989:2022




@sandserifcomics





Árvores de Decisão




- É um modelo de aprendizado **supervisionado** utilizado para **classificação** e **regressão**.
 - Ou seja, podem prever algo categórico ou numérico!
- Representa decisões na forma de uma **estrutura hierárquica** de perguntas e respostas.
- As árvores de decisão aceitam variáveis categóricas e numéricas **sem necessidade de normalização**








- O nó raiz e os nós internos representam as **variáveis preditoras** (também chamadas de **features**)
- Cada nó contém uma **condição de decisão** baseada em uma dessas variáveis.
- As folhas representam a **variável alvo (target)**





- Em **classificação**, cada folha indica uma **classe** (ex: *Mamífero*, *Máquina*).



- Em **regressão**, cada folha indica um **valor numérico estimado** (ex: preço, temperatura).

Como treinar uma árvore de decisão?




- **Árvores de classificação**
 - Árvores de regressão


Tem veículo próprio?	Acesso fácil a Transporte Público	Idade	Prefere transporte público?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não

- O primeiro passo é definir qual a primeira pergunta que deve estar no nó raiz
- Para isso, é necessário verificar qual variável preditora é a melhor em predizer o alvo


Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não




Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não



Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não






- A eficiência de um nó em uma árvore de decisão ao separar dados é determinada pela **medida de impureza**.
- Existem diversos métodos para quantificar a impureza de um nó:
 - **Gini Impurity**
 - Entropy
 - Information Gain
- A **impureza de Gini** mede a probabilidade de um elemento ser incorretamente classificado se fosse rotulado aleatoriamente de acordo com a distribuição dos rótulos no conjunto.


Gini Index

$$I_G = 1 - \sum_{j=1}^c p_j^2$$

p_j : proportion of the samples that belongs to class c for a particular node




Impureza de Gini para a folha = $1 - (prob.de "Sim")^2 - (prob.de "Não")^2$



Impureza de Gini para a folha = $1 - (\text{prob. de "Sim"})^2 - (\text{prob. de "Não"})^2$


$$\text{Impureza de Gini para a folha} = 1 - \left(\frac{1}{1+3}\right)^2 - \left(\frac{3}{1+3}\right)^2 = 0,375$$




Impureza de Gini para a folha = $1 - (prob. de "Sim")^2 - (prob. de "Não")^2$

$$Impureza de Gini para a folha = 1 - \left(\frac{2}{2+1}\right)^2 - \left(\frac{1}{2+1}\right)^2 = 0,444$$


Para obter a impureza total do nó, calculamos a impureza total através da média ponderada entre as impurezas das folhas



$$\text{Impureza de Gini Total} = \left(\frac{4}{4+3}\right) \times 0,375 + \left(\frac{3}{4+3}\right) \times 0,444 = \mathbf{0,405}$$




Impureza de Gini Total = 0,405



Impureza de Gini Total = 0,214

Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não

- Como calcular a impureza de Gini para uma variável numérica?





Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não

- Primeiramente, devemos reordenar a base para que a variável numérica fique em ordem crescente
- Depois, calculamos a média entre valores adjacentes
- Então, calculamos a Impureza de Gini para cada possível *split* na árvore

Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não

20
25
31,5
36,5
44
66,5



•
•
•

Tem veículo próprio?	Acesso fácil a Transporte Público (TP)	Idade	Prefere transporte público (TP)?
Sim	Sim	18	Não
Sim	Não	22	Não
Não	Sim	28	Sim
Não	Sim	35	Sim
Sim	Sim	38	Sim
Sim	Não	50	Não
Não	Não	83	Não

20 -> Impureza de Gini = 0,429

25 -> Impureza de Gini = 0,343

31,5 -> Impureza de Gini = 0,476


36,5 -> Impureza de Gini = 0,476

44 -> Impureza de Gini = 0,343

66,5 -> Impureza de Gini = 0,429


- Comparando os valores obtidos, a impureza de “Acesso fácil a transporte público?” é o menor e, por isso, estará no topo da árvore
- Como o nó da esquerda ainda está impuro, podemos continuar a desmembrar a nossa árvore*

**Cuidado com o overfit!*




Impureza de Gini Total = 0,214


- Para continuar o desenvolvimento da árvore, repetimos o mesmo processo que usamos para definir o nó raiz



- Para continuar o desenvolvimento da árvore, repetimos o mesmo processo que usamos para definir o nó raiz




- Para continuar o desenvolvimento da árvore, repetimos o mesmo processo que usamos para definir o nó raiz



Observações importantes:



- A variável “Tem veículo próprio?” não **faz parte da árvore resultante!** Ou seja, o modelo resultante não precisa dela para a classificação
- A resposta da folha sempre corresponderá à classe majoritária
- Quais são as limitações desse modelo?



Observação importante sobre overfitting:

- É preciso tomar cuidado com a **profundidade** (complexidade) da árvore com relação ao tamanho do dataset para evitar overfit.
- Uma árvore com apenas folhas puras é um indicativo de overfit.
- Como podemos evitar overfit?
 - Limitar a profundidade da árvore
 - Estabelecer um número mínimo de amostras no nó da árvore, mesmo que este não seja um nó puro
 - Número mínimo para fazer o split de um nó


Como treinar uma árvore de decisão?




- Árvores de classificação
- **Árvores de regressão**

A árvore de regressão é mais apropriada que a regressão linear quando os dados apresentam relações não lineares, interações complexas entre variáveis ou quando o comportamento da variável alvo muda abruptamente em diferentes faixas dos dados.

- Regressão Linear




- Árvores de Regressão





- Diferente das árvores de classificação onde utilizamos as medidas de impureza (gini, entropy, loss, etc), aqui utilizamos as métricas de regressão para definir o erro e avaliar a qualidade de um determinado corte no espaço.
- Soma dos Quadrados dos Resíduos (SSR):



$$SSR = \sum_{i=1}^n (y_i - f(x_i))^2$$





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR





- Para descobrir qual é o nó raiz da árvore, avalia-se cada possível split nos dados.
- Em cada um dos possíveis splits, calcula-se o valor de SSR



- Quando este processo estiver concluído, o menor valor SSR corresponderá ao nó raiz



- O processo se repete para novas ramificações



- Fáceis de construir
- Fáceis de interpretar e apresentar
- Úteis para exploração de dados e análise de importância de features
- Pode lidar com variáveis categóricas e contínuas
- Menos sensíveis a aos outliers e dados faltantes

- É preciso **tomar cuidado** para que não tenha **overfit** ao treinar o modelo
- Na prática **é difícil conseguir boa performance** com árvores de decisão e árvores de regressão simples.
- Normalmente, elas performam bem com os dados que foram usados para criar as árvores (treinar o modelo), mas tem uma **performance ruim com novos dados**.
- Em outras palavras, elas não são flexíveis para classificação ou regressão de novos dados

OBRIGADO PELA ATENÇÃO!



Prof. Dr. Arthur Henrique de Andrade Melani
Departamento de Engenharia Mecatrônica e Sistemas Mecânicos
Escola Politécnica da Universidade de São Paulo
melani@usp.br